MAESTRÍA EN CIENCIA DE DATOS

Modelos de Pronóstico: Aprendizaje Automático

Análisis profundo de series de tiempo: desde procesos estocásticos hasta modelado aditivo Bayesiano.

Fundamentos del Forecasting

Definición Matemática

Estimación del valor futuro y_{t+h} condicionado al conjunto de información histórica I_t.

A diferencia de la regresión clásica, los datos presentan **dependencia temporal** e infracción del supuesto de i.i.d.

Propósito del Análisis

- **Predicción:** Estimar valores futuros puntuales.
- **Incertidumbre:** Cuantificar el riesgo mediante intervalos.
- **Explicación:** Entender los generadores de la señal.

Anatomía de una Serie de Tiempo

Cualquier serie puede ser descompuesta en cuatro elementos fundamentales:

- **Tendencia (Trend):** Movimiento persistente a largo plazo.
- **Estacionalidad (Seasonality):** Patrones que se repiten en periodos fijos.
- **Ciclo:** Fluctuaciones sin periodo fijo (ej. ciclos económicos).
- **Irregular/Ruido:** Variaciones aleatorias e impredecibles.

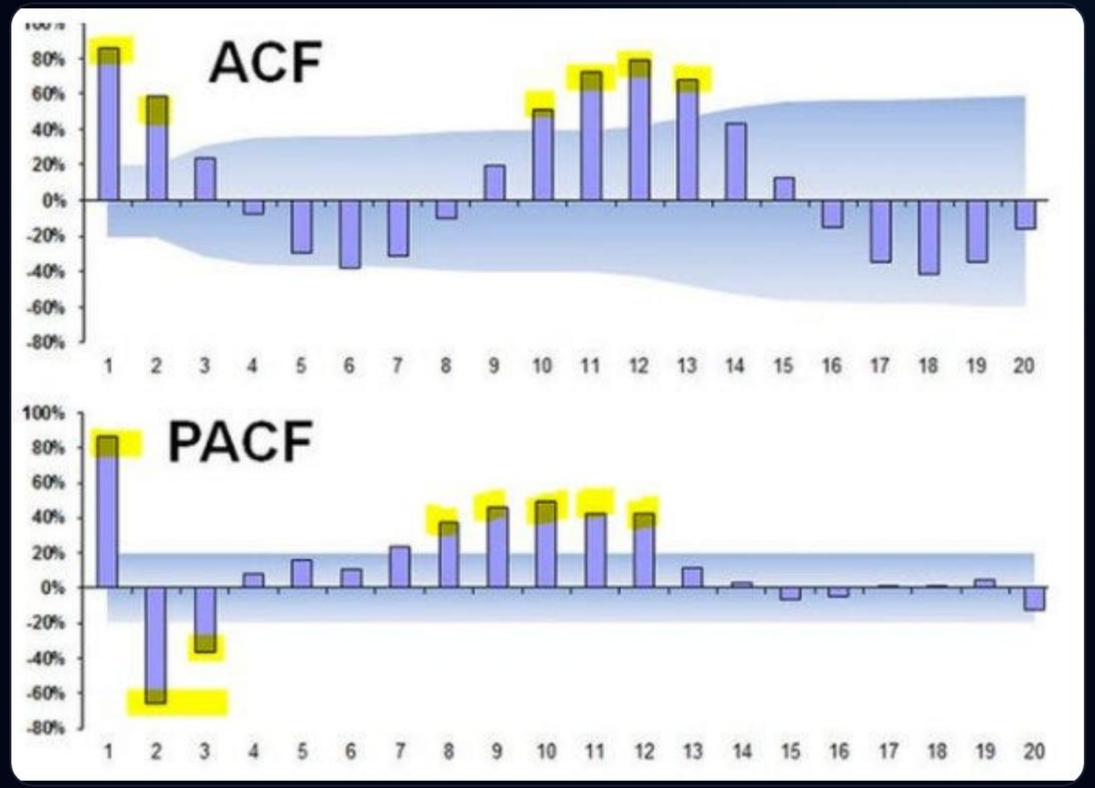

Autocorrelación (ACF)

Definición de ACF

Mide la correlación entre la serie y_t y una versión rezagada de sí misma y_{t-k}.

$$\rho_k = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)}$$

Utilidad Técnica:

- Detectar estacionalidad (picos en periodos fijos).
- Identificar el orden del componente de **Media Móvil (MA)**.
- Determinar si la serie es Ruido Blanco.

Autocorrelación Parcial (PACF)

Mide la correlación entre y_t y y_{t-k} **eliminando** el efecto de los rezagos intermedios.

> Excluye la influencia de $y_{t-1}, \cdots, y_{t-k+1}$.

Utilidad Técnica:

- Identificar el orden del componente **Autoregresivo (AR)**.
- Si la PACF corta tras el lag *p*, sugiere un modelo AR(p).

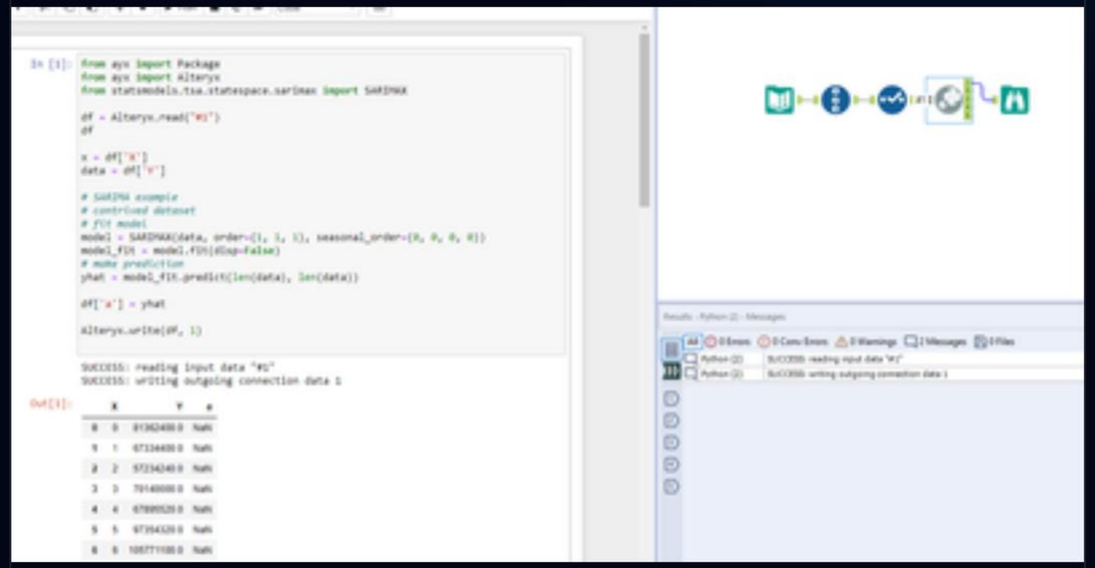

Modelos de Descomposición

Determinamos cómo se combinan los componentes para formar la serie observada:

Aditivo:

$$y_t = T_t + S_t + e_t$$

Multiplicativo:

$$y_t = T_t \times S_t \times e_t$$

El modelo multiplicativo es fundamental cuando la varianza estacional es proporcional al nivel.

Transformación de Box-Cox

Permite estabilizar la varianza antes de modelar, facilitando el uso de modelos aditivos en señales multiplicativas:

$$w_t = \frac{y_t^{\lambda} - 1}{\lambda}$$

Procesos Autorregresivos (AR)

El Modelo AR(p)

Predice el valor actual como una combinación lineal de sus propios **p** valores pasados:

$$y_t = c + \sum_{i=1}^{p} \phi_i y_{t-i} + \varepsilon_t$$

Identificación Técnica:

- **PACF:** Muestra un corte abrupto tras el lag *p*.
- **Estacionariedad:** Las raíces del polinomio característico deben estar fuera del círculo unitario.
- **Memoria:** El impacto de un shock decae exponencialmente pero persiste.

Media Móvil (MA)

El modelo **MA(q)** modela la serie en función de los errores de pronóstico pasados:

$$y_t = c + \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}$$

Identificación Técnica

- **ACF:** Muestra un corte abrupto tras el lag *q*.
- **Invertibilidad:** Asegura que el modelo se pueda representar como un AR(∞).
- **Memoria:** Los shocks tienen un efecto finito y desaparecen tras *q* periodos.

ARIMA e Integración

ARIMA(p, d, q)

Maneja la no-estacionariedad mediante el orden de diferenciación **(d)**:

$$\nabla^d y_t = (1 - B)^d y_t$$

Tests de Estacionariedad:

- **Augmented Dickey-Fuller (ADF):** Determina si existe una raíz unitaria.
- **KPSS:** Verifica estacionariedad frente a tendencia.

> Si p-value < 0.05 en ADF, rechazamos la no-estacionariedad.

SARIMAX: El Modelo Robusto

Expande ARIMA para modelar ciclos de larga duración (S) y variables externas (X):

S: Periodicidad (ej. s=12 mensual).

X: Regresores exógenos deterministas.

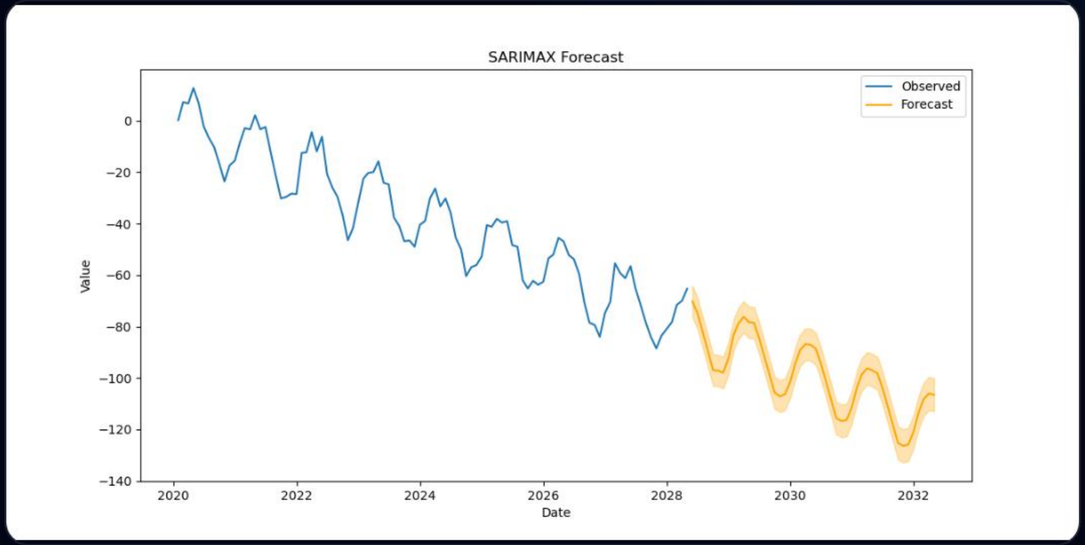

ETS: Suavizamiento Exponencial

Marco de estado-espacio que actualiza componentes basados en el error de predicción anterior:

Clasificación E-T-S:

- **Error:** Aditivo (A) o Multiplicativo (M).
- **Trend:** Ninguna (N), Aditiva (A) o Amortiguada (Ad).
- **Season:** Ninguna (N), Aditiva (A) o Multiplicativa (M).

Optimización

Se utiliza el criterio **AICc** para seleccionar la arquitectura óptima que minimice la pérdida de información.

TBATS: Estacionalidades Complejas

Capacidades de TBATS

Diseñado para señales que presentan múltiples periodos estacionales (ej. ciclos diarios y semanales) o estacionalidades no enteras.

> **T:** Trigonometric seasonality (Fourier).

Acrónimo Técnico:

- **B:** Box-Cox transformation.
- **A:** ARMA error process.
- **T:** Trend (incluyendo damping).
- **S:** Seasonal components.

TBATS: Estacionalidad Trigonométrica

Modela el ciclo estacional *i* mediante la suma de armónicos:

Esta técnica permite una representación parsimoniosa de ciclos largos sin necesidad de un parámetro por cada lag estacional.

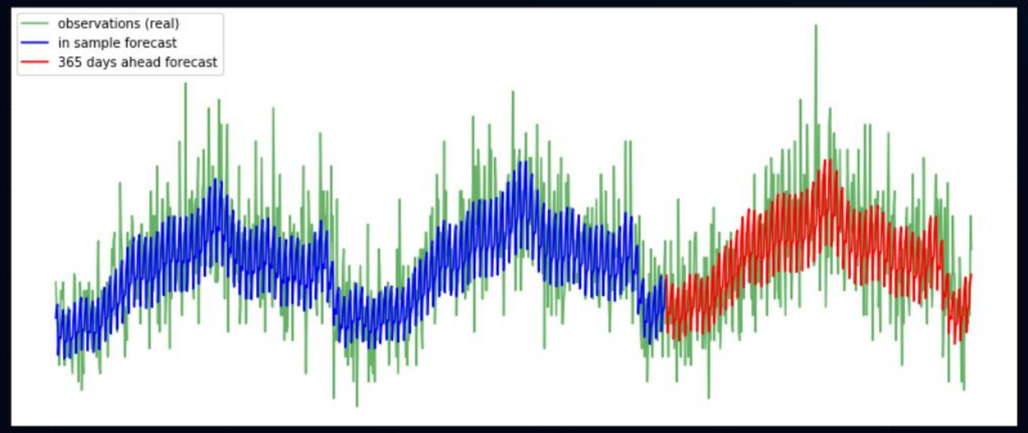

Facebook Prophet

Aproxima la serie mediante una descomposición aditiva modular ajustada por regresión:

g(t): Tendencia (lineal o logística con *changepoints*).

s(t): Estacionalidad (Series de Fourier).

h(t): Efecto de festivos (User-defined).

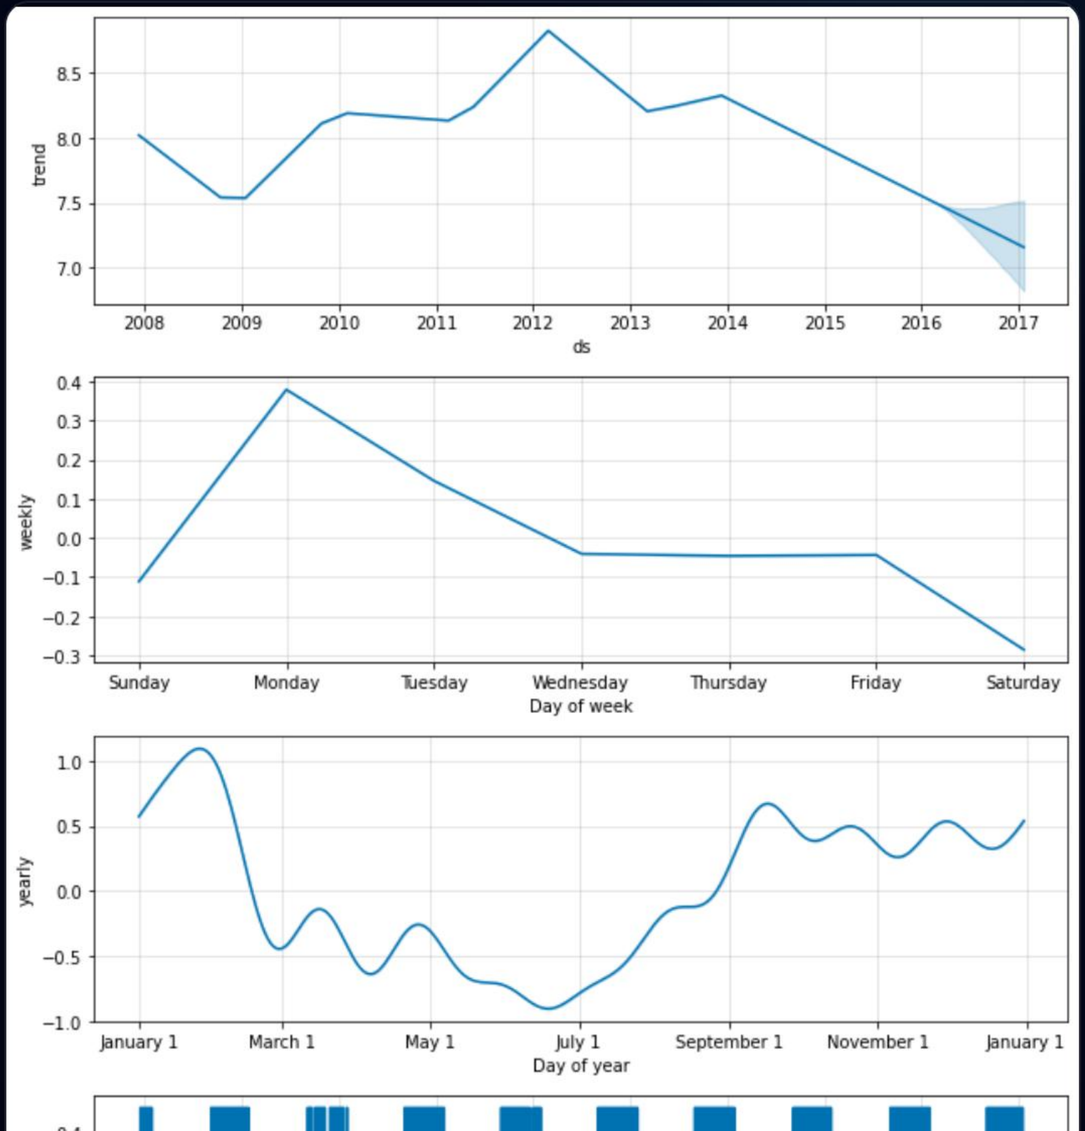

Python: pmdarima & statsmodels

sarimax_model.py

```
import pmdarima as pm # Auto-ARIMA busca la mejor combinación (p,d,q)x(P,D,Q)s model = pm.auto_arim
```

Python: Suavizamiento Exponencial

holt_winters.py

```
from statsmodels.tsa.holtwinters import ExponentialSmoothing # Ajustar Holt-Winters Aditivo/Multipl
```

Python: Librería TBATS

tbats_forecaster.py

```
from tbats import TBATS # Definir múltiples periodos (Semanal y Anual) estimator = TBATS(seasonal_p
```

Python: Facebook Prophet

prophet_forecaster.py

```
from prophet import Prophet # Prophet exige nombres 'ds' y 'y' m = Prophet(yearly_seasonality=True)
```

Métricas de Evaluación

Escalares (MAE, RMSE)

MAE: Promedio de errores absolutos. Fácilmente interpretable.

RMSE: Penaliza errores grandes (cuadrático). Crucial para minimizar riesgos atípicos.

Porcentuales y Relativas

MAPE: Error porcentual promedio. Falla si $y_t=0$.

MASE: Compara contra un pronóstico *Naive*. Indica si el modelo supera la media histórica.

Validación Cruzada Temporal

Debido a la dependencia temporal, no se puede usar K-Fold aleatorio (Data Leakage).

Se utiliza **Time Series Split**:

- Ventana de entrenamiento expandible.
- Validación siempre posterior al entrenamiento.
- Medición robusta de la capacidad de generalización.

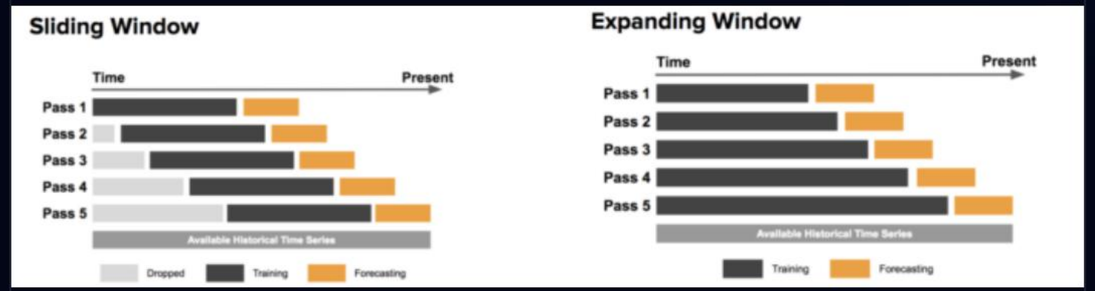

¿Preguntas?

Aprendizaje Automático Aplicado a Series de Tiempo

MAESTRÍA EN CIENCIA DE DATOS | 2024

Image Sources

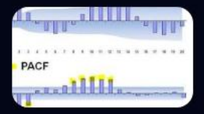

https://miro.medium.com/1*SlmQlOYrwVyngsH5bh0iCA.jpeg

Source: itsudit.medium.com

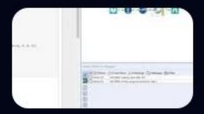

https://community.alteryx.com/t5/image/serverpage/image-id/212603iB7E734712DAE0DDA/image-size/medium?v=v2&px=400

Source: community.alteryx.com

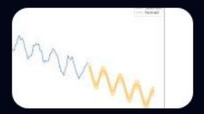

https://substackcdn.com/image/fetch/$s_!Wo71!,f_auto,q_auto:good,fl_progressive:steep/https%3A%2F%2Fsubstack-post-media.s3.amazonaws.com%2Fpublic%2Fimages%2Fa76e4b10-6391-40b4-b4df-092e4e661b03_1200×600.png

Source: abouttrading.substack.com

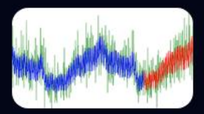

https://miro.medium.com/1*7rH9cl3tiXUmPjCnQh66aw.png

Source: medium.com

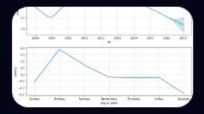

https://facebook.github.io/prophet/static/seasonality,_holiday_effects,_and_regressors_files/seasonality,_holiday_effects,_and_regressors_52_0.png

Source: facebook.github.io

---

https://i.stack.imgur.com/8qeEX.png

Source: www.reddit.com