MAESTRÍA EN CIENCIA DE DATOS

Modelos de Pronóstico: Aprendizaje Automático

Análisis profundo de series de tiempo: desde procesos estocásticos hasta modelos aditivos Bayesianos.

Fundamentos del Forecasting

Definición Matemática

Estimación del valor futuro y_{t+h} condicionado a la información histórica I_t. A diferencia de la regresión clásica, los datos presentan **dependencia temporal**.

Componentes de la Señal

Toda serie temporal y_t se descompone en:

- **Tendencia:** Movimiento de largo plazo.
- **Estacionalidad:** Variaciones periódicas.
- **Residuo:** Ruido blanco o error estocástico.

Descomposición de Series

Existen dos formas principales de modelar la interacción de componentes:

Modelo Aditivo:

$$y_t = T_t + S_t + e_t$$

Modelo Multiplicativo:

$$y_t = T_t \times S_t \times e_t$$

Usamos el multiplicativo cuando la amplitud de la estacionalidad varía proporcionalmente a la tendencia.

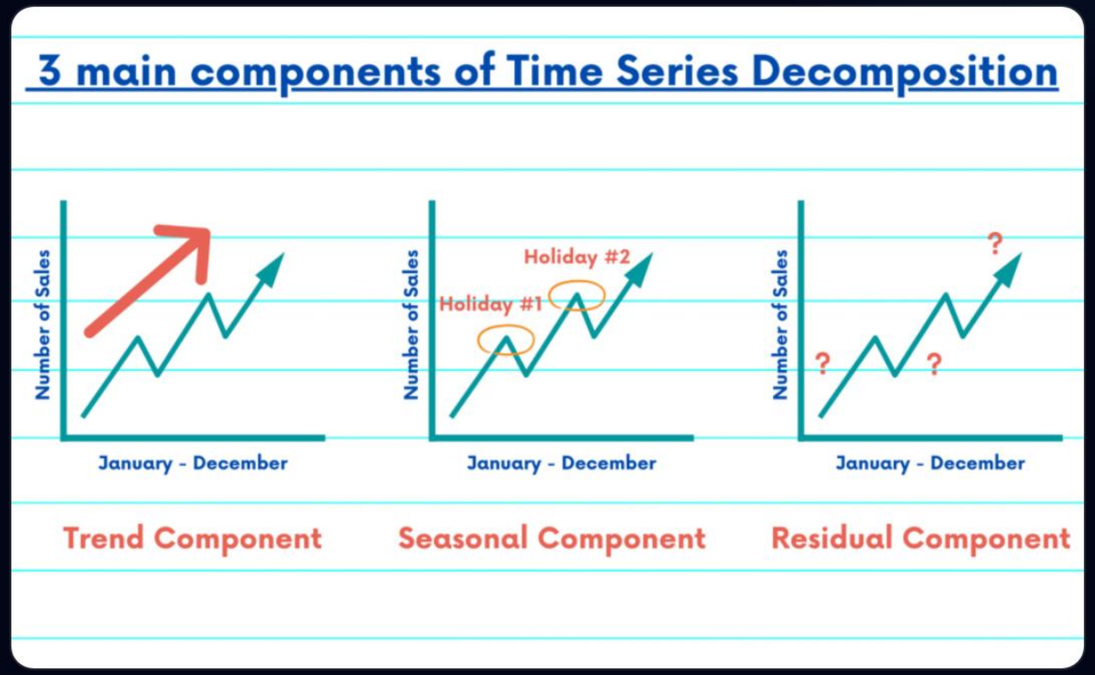

Procesos Autorregresivos (AR)

Un proceso **AR(p)** asume que el valor actual depende linealmente de sus **p** valores anteriores:

$$y_t = c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t$$

Identificación: Se utiliza la función de autocorrelación parcial (**PACF**). Si la PACF corta abruptamente tras el lag *p*, sugiere un modelo AR(p).

Criterio Técnico

Para que el modelo sea estable, las raíces del polinomio característico deben caer fuera del círculo unitario. Esto garantiza que la serie no "explote" hacia el infinito.

Procesos de Media Móvil (MA)

Definición de MA(q)

A diferencia de AR, un proceso MA(q) asume que el valor actual depende de los **errores de pronóstico pasados**:

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Identificación: Se utiliza la función de autocorrelación (**ACF**). Si la ACF corta tras el lag *q*, indica un modelo MA(q).

Invertibilidad: Un modelo MA siempre es estacionario, pero buscamos que sea invertible para poder representarlo como un proceso AR infinito.

ARIMA: Integración y Estacionariedad

El modelo **ARIMA(p, d, q)** introduce la diferenciación **(d)** para estabilizar la media:

$$\nabla^d y_t = (1 - B)^d y_t$$

Tests de Estacionariedad:

- **ADF (Dickey-Fuller):** Busca raíces unitarias.
- **KPSS:** Verifica estacionariedad de tendencia.

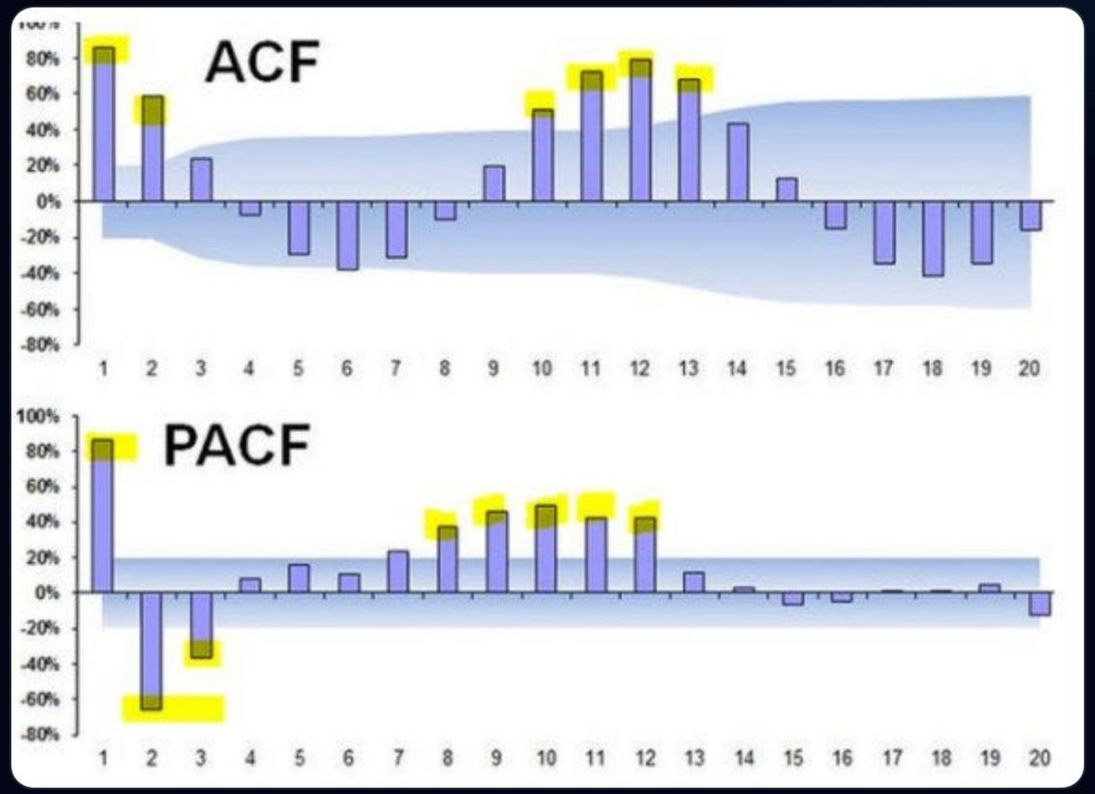

SARIMAX: Estacionalidad y Exógenas

Extiende ARIMA para manejar patrones estacionales (S) y variables exógenas (X). Su estructura es:

$$\text{SARIMAX}(p, d, q) \times (P, D, Q, s)$$

Variables Exógenas (X)

Permite incluir regresores externos X_t (ej: clima, promociones). El modelo estima el impacto de *X* mientras modela los residuos estocásticos.

Diferenciación Estacional (D)

Elimina la estacionalidad restando el valor del mismo periodo en el ciclo anterior: $y_t - y_{t-s}$.

ETS: Error, Tendencia, Estacionalidad

Basado en el Suavizamiento Exponencial, utiliza ecuaciones de estado para actualizar componentes:

Ecuación de Nivel (Level):

$$l_t = \alpha (y_t / s_{t-m}) + (1 - \alpha) (l_{t-1} + b_{t-1})$$

- **SES:** Suavizamiento simple (sin tendencia).
- **Holt:** Añade tendencia lineal.
- **Holt-Winters:** Añade estacionalidad (Aditiva o Multiplicativa).

Selección vía **AIC (Akaike Information Criterion)**.

TBATS: Estacionalidad Trigonométrica

Ideal para series con múltiples estacionalidades (ej: diaria y semanal) o ciclos no enteros.

Trigonometric Seasonal

Utiliza series de **Fourier** para modelar la estacionalidad:

$$\sum_{j=1}^{k_i} [\alpha_{i,j} \sin(\lambda_{i,j} t) + \beta_{i,j} \cos(\lambda_{i,j} t)]$$

Acrónimo Técnico

- **T:** Trigonometric seasonality
- **B:** Box-Cox transformation
- **A:** ARMA errors
- **T:** Trend (damping)
- **S:** Seasonal components

Facebook Prophet: Enfoque Aditivo

Prophet rompe con la estructura ARIMA y trata el problema como una **curva de regresión ajustada** (GAM):

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

g(t): Tendencia (lineal o logística con puntos de cambio).

s(t): Estacionalidad (Series de Fourier).

h(t): Efecto de festivos (Holidays).

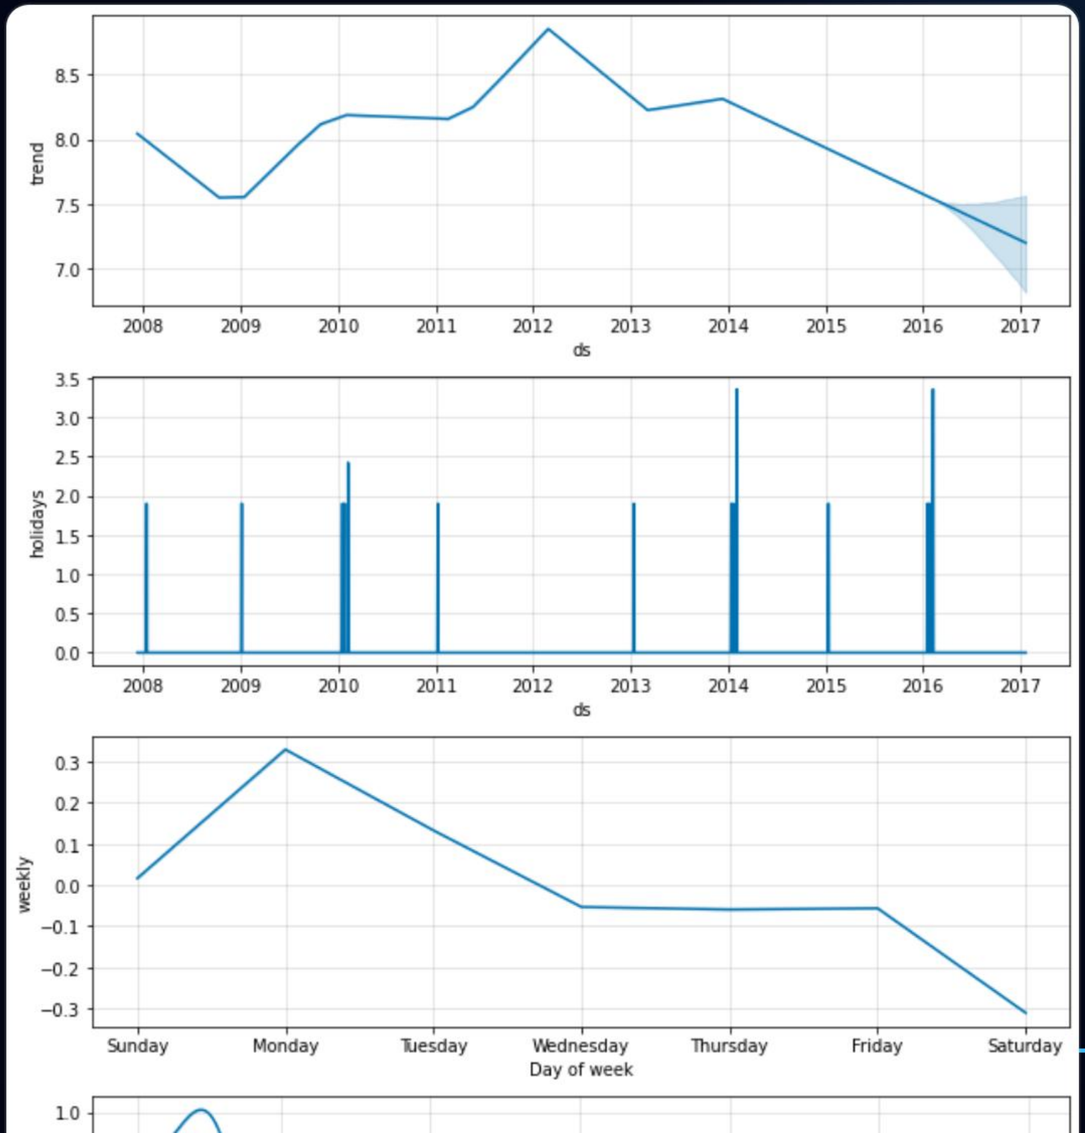

Implementación en Python

PMDARIMA & STATSMODELS

```
import pmdarima as pm # Auto-ARIMA automático
model = pm.auto_arima(y, seasonal=True, m=12)
from statsmodels.tsa.holtwinters import
ExponentialSmoothing # Modelo Holt-Winters hw =
ExponentialSmoothing(y, trend='add',
seasonal='mul').fit()
```

PROPHET & TBATS

```
from prophet import Prophet m = Prophet()
m.fit(df) # DF con ds y y from tbats import TBATS
estimator = TBATS(seasonal_periods=[7, 365.25])
model = estimator.fit(y)
```

Métricas de Evaluación de Pronóstico

Escalares (MAE, RMSE)

MAE: Promedio de errores absolutos. Fácil de interpretar en la unidad original.

RMSE: Penaliza errores grandes (outliers) debido al cuadrado.

Porcentuales y Relativas

MAPE: Útil para comparar entre series de distintas magnitudes, pero falla si $y_t = 0$.

MASE: Compara el error del modelo contra un pronóstico *Naive* (sin cambios). Si MASE < 1, el modelo es mejor que el naive.

Validación Cruzada Temporal

No se puede usar K-Fold aleatorio debido a la fuga de datos (Data Leakage). Se utiliza **Expanding Window**:

- **Step 1:** Entrena 1:100, predice 101:110.
- **Step 2:** Entrena 1:110, predice 111:120.
- **Step 3:** Entrena 1:120, predice 121:130.

Evita entrenar con información del "futuro".

¿Preguntas?

Gracias por su atención.

Maestría en Ciencia de Datos | Aprendizaje Automático Aplicado

Image Sources

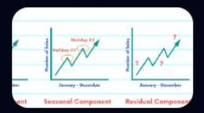

https://nebigdatahub.org/wp-content/uploads/2023/11/3-Decomposition-1-1024×576.png

Source: nebigdatahub.org

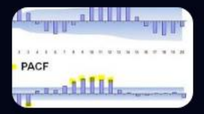

https://miro.medium.com/1*SlmQIOYrwVyngsH5bh0iCA.jpeg

Source: itsudit.medium.com

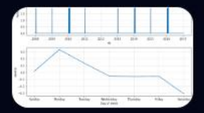

https://facebook.github.io/prophet/static/seasonality,_holiday_effects,_and_regressors_files/seasonality,_holiday_effects,_and_regressors_14_0.png

Source: facebook.github.io